


Laporan Akhir UAS Praktikum Machine Learning

INSECTIQ – SMART INSECT IDENTIFIER & AI INSIGHTS

disusun untuk memenuhi
mata kuliah Machine Learning

Oleh:

Muhammad Ikram Ramadhana Friyan
(2308107010055)



**JURUSAN INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA
DARUSSALAM, BANDA ACEH
2026**

BAB I

PENDAHULUAN

1.1 Latar Belakang

InsectIQ adalah sistem identifikasi serangga otomatis berbasis kecerdasan buatan yang dikembangkan sebagai bagian dari Final Project Praktikum Pembelajaran Mesin. Sistem ini mampu mengenali spesies serangga dari gambar yang diunggah oleh pengguna, kemudian memberikan wawasan mendalam mengenai taksonomi, habitat, dan fakta menarik menggunakan integrasi Large Language Model (LLM) Google Gemini 2.5 Flash Lite.

Proyek ini memadukan teknik Transfer Learning menggunakan arsitektur EfficientNet-B3 dengan dataset gambar serangga berisi 118 kelas yang bersumber dari Kaggle dengan total ukuran 5.52 GB, serta membangun pipeline lengkap mulai dari pelatihan model, pengembangan REST API menggunakan FastAPI, hingga antarmuka pengguna modern berbasis Next.js dan Tailwind CSS.

1.2 Tujuan

- Membangun model klasifikasi gambar serangga dengan akurasi tinggi menggunakan Transfer Learning EfficientNet-B3.
- Mengintegrasikan model dengan REST API berbasis FastAPI untuk kebutuhan inference.
- Mengintegrasikan Gemini 2.5 Flash Lite untuk memberikan informasi spesies secara otomatis.
- Membangun antarmuka pengguna yang modern, responsif, dan intuitif menggunakan Next.js.

BAB II

METODOLOGI

2.1 Dataset

Dataset yang digunakan adalah Insect Classification dari Kaggle (baxtiyorbotiraliyev/insects) dengan total ukuran 5.52 GB. Dataset ini telah dibagi menjadi tiga subset resmi yaitu train, validation, dan test dengan total 118 kelas serangga yang berbeda. Pada tahap preprocessing, dilakukan pemindaian seluruh file gambar untuk mendeteksi dan melewati gambar yang rusak (corrupt) agar proses pelatihan berjalan dengan benar.

2.2 Arsitektur Model

Model yang digunakan adalah EfficientNet-B3 dengan pendekatan Transfer Learning menggunakan library timm (PyTorch Image Models). EfficientNet-B3 dipilih karena keseimbangan optimal antara akurasi dan efisiensi komputasi dibandingkan arsitektur lain seperti ResNet atau MobileNet. Berikut adalah konfigurasi hyperparameter yang digunakan dalam proses pelatihan.

Parameter	Nilai
Arsitektur	EfficientNet-B3 (timm)
Input Size	300 × 300 px
Pretrained Weights	ImageNet
Optimizer	AdamW (lr=1e-4, weight_decay=1e-4)
Loss Function	CrossEntropyLoss (label_smoothing=0.1)
Scheduler	CosineAnnealingLR
Batch Size	32
Early Stopping	Patience = 7 epoch
Epochs	50 (berhenti di epoch ke-19)

Tabel 1. Konfigurasi Hyperparameter Model

2.3 Preprocessing dan Augmentasi Data

Pada proses pelatihan, dilakukan berbagai teknik augmentasi data untuk meningkatkan generalisasi model. Augmentasi yang diterapkan meliputi resize gambar ke 320×320 kemudian random crop ke 300×300, random horizontal flip dengan probabilitas 0.5, random vertical flip dengan probabilitas 0.2, rotasi acak ± 20 derajat, color jitter untuk brightness, contrast, saturation, dan hue, serta normalisasi menggunakan mean dan standar deviasi ImageNet ([0.485, 0.456, 0.406] dan [0.229, 0.224, 0.225]).

2.4 Struktur Direktori Proyek

Berikut adalah struktur direktori proyek InsectIQ yang dibangun dalam final project ini.

```
InsectIQ/
├── files/
│   └── notebook.ipynb
├── backend/
│   ├── artifacts/
│   │   ├── model_scripted.pt
│   │   └── metadata.json
│   ├── .env
│   ├── gemini_service.py
│   ├── main.py
│   ├── ml_service.py
│   └── requirements.txt
└── frontend/
    ├── app/
    │   ├── page.tsx
    │   ├── layout.tsx
    │   └── globals.css
    ├── components/
    │   └── ResultCard.tsx
    ├── package.json
    └── tailwind.config.ts
```

Gambar 1. Struktur Direktori Proyek InsectIQ

2.5 Pengembangan Backend (FastAPI)

Backend dibangun menggunakan framework FastAPI berbasis Python yang menyediakan REST API untuk kebutuhan inference model dan integrasi dengan layanan Gemini. Backend terdiri dari beberapa komponen utama sebagai berikut. Pertama, `ml_service.py` merupakan kelas yang bertanggung jawab memuat model TorchScript (.pt) dari direktori artifacts saat aplikasi pertama kali dijalankan, kemudian melakukan

preprocessing gambar (resize, normalisasi) dan inference untuk menghasilkan prediksi top-3 kelas beserta nilai confidence-nya.

Kedua, `gemini_service.py` merupakan kelas yang mengelola integrasi dengan Google Gemini 2.5 Flash Lite melalui SDK `google-generativeai`. Kelas ini membangun prompt dalam Bahasa Indonesia yang meminta Gemini memberikan informasi taksonomi, habitat, dan fun facts serangga yang terdeteksi, dengan opsi Google Search Grounding untuk memperoleh data terkini dari internet.

Ketiga, `main.py` berfungsi sebagai entry point aplikasi yang mendefinisikan endpoint POST `/predict`. Endpoint ini menerima file gambar dari pengguna, menjalankan inference ML, kemudian memanggil Gemini untuk mendapatkan AI insights. Backend juga mengimplementasikan fallback mechanism sehingga apabila layanan Gemini tidak tersedia (error 503), hasil prediksi model tetap dikembalikan kepada pengguna beserta pesan bahwa AI insights sedang tidak tersedia.

Backend dijalankan menggunakan Uvicorn sebagai ASGI server dengan perintah `uvicorn main:app --reload`, dan dapat diakses melalui `http://localhost:8000` dengan dokumentasi API otomatis di `http://localhost:8000/docs`.

Library/Tools	Fungsi
FastAPI	Framework REST API utama
Uvicorn	ASGI server untuk menjalankan FastAPI
PyTorch + timm	Load dan inference model EfficientNet-B3
Pillow	Decode dan preprocessing gambar
google-generativeai	SDK untuk integrasi Gemini API
python-dotenv	Membaca konfigurasi dari file <code>.env</code>
python-multipart	Parsing file upload dari request

Tabel 2. Library yang Digunakan pada Backend

2.6 Pengembangan Frontend (Next.js)

Frontend dibangun menggunakan Next.js 15 dengan TypeScript dan Tailwind CSS sebagai framework styling. Antarmuka pengguna dirancang dengan tema dark navy futuristik yang menampilkan elemen-elemen visual seperti grid background, HUD corner brackets, dan animasi scan line untuk memberikan kesan modern dan profesional.

Komponen utama frontend terdiri dari halaman utama (page.tsx) yang mengelola seluruh state aplikasi menggunakan React hooks, mulai dari state idle saat belum ada gambar, state uploading saat gambar sudah dipilih, state analyzing saat proses prediksi berlangsung ditandai dengan animasi scanner, hingga state done saat hasil prediksi tersedia. Komponen ResultCard.tsx bertanggung jawab merender respons Markdown dari Gemini menggunakan library react-markdown dengan plugin remark-gfm untuk mendukung format tabel dan list.

Komunikasi antara frontend dan backend dilakukan melalui HTTP request ke endpoint /api/predict menggunakan Fetch API. Next.js dikonfigurasi untuk melakukan rewrite request dari /api/* ke http://localhost:8000/* sehingga tidak terjadi CORS issue. Frontend dijalankan dengan perintah npm run dev dan dapat diakses di http://localhost:3000.

Library/Tools	Fungsi
Next.js 15	Framework React untuk pengembangan web
TypeScript	Type-safe JavaScript
Tailwind CSS	Utility-first CSS framework untuk styling
Framer Motion	Library animasi (scan effect, transisi halaman)
react-markdown + remark-gfm	Render respons Markdown dari Gemini
lucide-react	Icon library


Tabel 3. Library yang Digunakan pada Frontend

BAB III

EVALUASI MODEL

3.1 Hasil Pelatihan

Model EfficientNet-B3 dilatih menggunakan GPU T4 x2 di Kaggle Notebook selama sekitar 6 jam. Early stopping terpicu pada epoch ke-19 karena validation loss tidak mengalami perbaikan selama 7 epoch berturut-turut. Model terbaik disimpan berdasarkan validation accuracy tertinggi dan diekspor ke format TorchScript (.pt) untuk digunakan pada tahap deployment.



Gambar 2. Kurva Training dan Validation — Loss dan Accuracy

3.2 Analisis Kurva Training

Berdasarkan kurva training pada Gambar 2, dapat diamati beberapa hal penting. Pertama, training loss turun secara konsisten dari sekitar 2.3 pada epoch pertama hingga mendekati 1.0 pada epoch terakhir. Sementara itu, validation loss stabil di sekitar 1.37 setelah epoch ke-5, yang menunjukkan konvergensi model yang baik.

Training accuracy mencapai sekitar 94% sementara validation accuracy stabil di sekitar 84%, mengindikasikan adanya slight overfitting dengan gap sekitar 10%. Hal ini wajar mengingat jumlah kelas yang sangat banyak (118 kelas) dan variasi gambar yang beragam dalam dataset.


3.3 Confusion Matrix

Gambar 3. Confusion Matrix pada Test Set (118 Kelas)


Confusion matrix pada Gambar 3 menunjukkan bahwa sebagian besar prediksi berada pada diagonal utama matriks, yang menandakan model berhasil mengklasifikasikan sebagian besar kelas dengan benar. Beberapa kelas yang memiliki nilai prediksi lebih tinggi (warna biru lebih gelap) adalah kelas-kelas dengan jumlah sampel yang lebih banyak dalam dataset training.

3.4 Screenshot Aplikasi

Berikut adalah tampilan antarmuka aplikasi InsectIQ saat sebelum dan saat berhasil melakukan prediksi terhadap gambar serangga yang diunggah oleh pengguna.



Gambar 4. Tampilan Antarmuka InsectIQ



Gambar 5. Tampilan Antarmuka InsectIQ Saat Melakukan Prediksi

BAB IV

ANALISIS GEMINI

4.1 Integrasi Gemini 2.5 Flash Lite

Gemini 2.5 Flash Lite diintegrasikan melalui Google Generative AI SDK dengan konfigurasi `temperature=0.7`, `top_p=0.95`, dan `max_output_tokens=1500`. Model ini dipanggil secara otomatis setelah proses inference ML selesai untuk memberikan informasi yang lebih lengkap mengenai spesies yang terdeteksi, meliputi nama ilmiah, taksonomi, habitat, dan fun facts. Tersedia juga opsi Google Search Grounding yang dapat diaktifkan pengguna untuk mendapatkan informasi terkini dari internet.

4.2 Analisis Jawaban Gemini

Berdasarkan pengujian terhadap beberapa prediksi model, respons yang dihasilkan Gemini cukup akurat dan relevan. Gemini memberikan informasi taksonomi yang lengkap meliputi nama ilmiah, nama umum dalam Bahasa Indonesia, genus, famili, deskripsi spesies, habitat dan persebaran geografis, serta fakta menarik yang bersifat edukatif.

Sebagai contoh, untuk prediksi "Ant" dengan tingkat kepercayaan 88.3%, Gemini memberikan informasi bahwa semut termasuk dalam famili Formicidae, merupakan serangga sosial dengan struktur koloni yang kompleks, dan dapat ditemukan di hampir semua habitat darat di seluruh dunia. Jawaban diformat dalam Markdown dan dirender dengan baik di frontend menggunakan library react-markdown.

4.3 Fallback Mechanism

Backend mengimplementasikan fallback mechanism untuk menangani kondisi ketika API Gemini tidak tersedia. Apabila API Gemini mengembalikan error 503 (Service Unavailable) atau error lainnya, sistem tetap menampilkan hasil prediksi model ML beserta pesan bahwa AI Insights sedang tidak tersedia. Dengan demikian, fungsionalitas inti aplikasi tidak terganggu meskipun layanan Gemini sedang mengalami gangguan.

BAB V

SARAN PENGEMBANGAN

5.1 Peningkatan Akurasi Model

- Melakukan fine-tuning lebih lanjut dengan membuka layer backbone secara bertahap (progressive unfreezing) untuk mendapatkan fitur yang lebih spesifik terhadap dataset serangga.
- Menambahkan teknik augmentasi yang lebih agresif seperti MixUp, CutMix, atau RandAugment untuk meningkatkan robustness model.
- Mencoba arsitektur yang lebih modern seperti EfficientNetV2, ConvNeXt, atau Vision Transformer (ViT) yang mungkin memberikan akurasi lebih tinggi.
- Mengatasi class imbalance menggunakan weighted random sampling atau focal loss agar model lebih merata dalam mengenali semua kelas.

5.2 Peningkatan Fitur Aplikasi

- Menambahkan fitur riwayat prediksi (prediction history) yang tersimpan secara lokal di browser pengguna.
- Implementasi visualisasi Grad-CAM untuk menunjukkan area gambar yang menjadi fokus model dalam mengambil keputusan prediksi.
- Menambahkan fitur upload batch (multiple images) sekaligus untuk efisiensi penggunaan.
- Optimasi ukuran model menggunakan teknik quantization atau ekspor ke format ONNX untuk inference yang lebih cepat di CPU.

5.3 Peningkatan Infrastruktur

- Men-deploy backend ke layanan cloud seperti Google Cloud Run atau Railway agar aplikasi dapat diakses secara publik.
- Mengimplementasikan caching hasil respons Gemini untuk menghemat penggunaan API quota pada pertanyaan yang sama.
- Menambahkan rate limiting dan autentikasi pada endpoint API untuk keamanan dan kontrol penggunaan.